DataFrame数据类型

DataFrame 是 Pandas 的重要数据结构之一，也是在使用 Pandas 进行数据分析过程中最常用的结构之一，可以这么说，掌握了 DataFrame 的用法，你就拥有了学习数据分析的基本能力。

认识DataFrame结构

DataFrame 一个表格型的数据结构，既有行标签（index），又有列标签（columns），它也被称异构数据表，所谓异构，指的是表格中每列的数据类型可以不同，比如可以是字符串、整型或者浮点型等。其结构图示意图，如下所示：

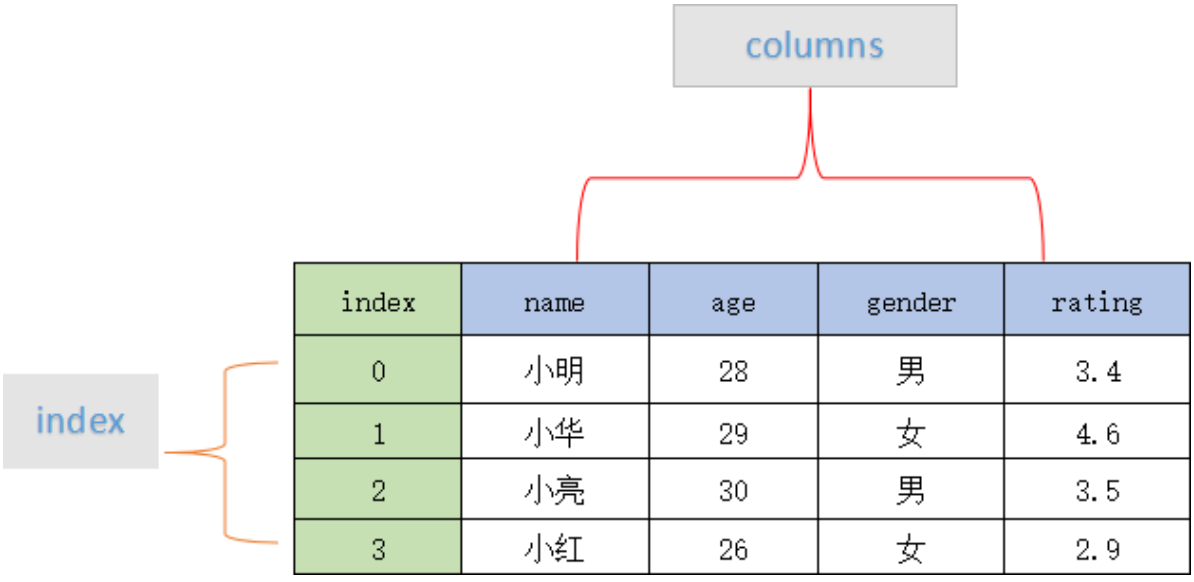

表格中展示了某个销售团队个人信息和绩效评级（rating）的相关数据。数据以行和列形式来表示，其中每一列表示一个属性，而每一行表示一个条目的信息。

下表展示了上述表格中每一列标签所描述数据的数据类型，如下所示：

Column	Type
name	String
age	integer
gender	String
rating	Float

DataFrame 的每一列数据都可以看成一个 Series 结构，只不过，DataFrame 为每列数据值增加了一个列标签。因此 DataFrame 其实是从 Series 的基础上演变而来,并且他们有相同的标签,在数据分析任务中 DataFrame 的应用非常广泛，因为它描述数据的更为清晰、直观。

通过示例对 DataFrame 结构做进一步讲解。 下面展示了一张学生评分表，如下所示：

Series1

	name
0	小明
1	小花
2	小李
3	小张

+ Series2

	age
0	28
1	29
2	30
3	26

+ Series3

	gender
0	男
1	女
2	男
3	女

+ Series4

	rating
0	3.4
1	4.6
2	3.5
3	2.9

= DataFrame

	name	age	gender	rating
0	小明	28	男	3.4
1	小花	29	女	4.6
2	小李	30	男	3.5
3	小张	26	女	2.9

同 Series 一样，DataFrame 自带行标签索引，默认为“隐式索引”即从 0 开始依次递增，行标签与 DataFrame 中的数据项一一对应。上述表格的行标签从 0 到 3，共记录了 4 条数据（图中将行标签省略）。当然你也可以用“显式索引”的方式来设置行标签。

下面对 DataFrame 数据结构的特点做简单地总结，如下所示：

- DataFrame 每一列的标签值允许使用不同的数据类型；
- DataFrame 是表格型的数据结构，具有行和列；
- DataFrame 中的每个数据值都可以被修改。
- DataFrame 结构的行数、列数允许增加或者删除；
- DataFrame 有两个方向的标签轴，分别是行标签和列标签；
- DataFrame 可以对行和列执行算术运算。

创建DataFrame对象

`pandas.DataFrame(data=None, index=None, columns=None, dtype=None, copy=None)`

- data: 输入的数据，可以是 ndarray，series，list，dict，标量以及一个 DataFrame
- index: 行标签，如果没有传递 index 值，则默认行标签是 RangeIndex(0, 1, 2, …, n)，n 代表 data 的元素个数。
- columns: 列标签，如果没有传递 columns 值，则默认列标签是 RangeIndex(0, 1, 2, …, n)。
- dtype: 要强制的数据类型。只允许使用一种数据类型。如果没有，自行推断
- copy: 从输入复制数据。对于dict数据，copy=True,重新复制一份。对于DataFrame或ndarray输入，类似于copy=False,使用的是试图

Pandas DataFrame 是一个二维的数组结构，类似二维数组。

```
# 引入numpy和pandas
import numpy as np

import pandas as pd
```

1. 使用普通列表创建

```
data = [1,2,3,4,5]
df = pd.DataFrame(data)
print(df)
```

```
   0
0  1
1  2
2  3
3  4
4  5
```

```
data = [1,2,3,4,5]
df = pd.Series(data)
print(df)
```

```
0    1
1    2
2    3
3    4
4    5
dtype: int64
```

2. 使用嵌套列表创建

```
# 列表中每个元素代表一行数据
data = [['xiaowang',20],['Lily',30],['Anne',40]]
# 未分配列标签
df = pd.DataFrame(data)

print(df)
```

```
          0   1
0  xiaowang  20
1      Lily  30
2      Anne  40
```

```
data = [['xiaowang',20],['Lily',30],['Anne',40]]
# 分配列标签
df = pd.DataFrame(data,columns=['Name','Age'])

print(df)
```

```
       Name  Age
0  xiaowang   20
1      Lily   30
2      Anne   40
```

3 指定数值元素的数据类型为 **float**：

- 需要注意,dtype只能设置一个, 设置多个列的数据类型,需要使用其他方式

```
data = [['xiaowang', 20, "男", 5000],['Lily', 30, "男", 8000],
['Anne', 40, "女", 10000]]
# 分配列标签
df = pd.DataFrame(data,columns=['Name','Age',"gender", "salary"],
dtype=int)
# int满足某列特征,会自动使用, 不满足,则自动识别
print(df)
```

```
      Name  Age gender  salary
0  xiaowang   20      男    5000
1      Lily   30      男    8000
2      Anne   40      女   10000
```

```
data = [['xiaowang', 20, "男", 5000.50],['Lily', 30, "男", 8000],
['Anne', 40, "女", 10000]]
# 分配列标签
#df = pd.DataFrame(data,columns=['Name','Age',"gender", "salary"],
dtype=[str,int,str,float])  #错误
df = pd.DataFrame(data,columns=['Name','Age',"gender", "salary"],
dtype=int)
# int满足某列特征,会自动使用, 不满足,则自动识别
print(df)

print(df['salary'].dtype)
```

```
      Name  Age gender   salary
0  xiaowang   20      男   5000.5
1      Lily   30      男   8000.0
2      Anne   40      女  10000.0
float64
```

4. 字典嵌套列表创建

data 字典中，键对应的值的元素长度必须相同（也就是列表长度相同）。如果传递了索引，那么索引的长度应该等于数组的长度；如果没有传递索引，那么默认情况下，索引将是 **RangeIndex(0.1...n)**，其中 **n** 代表数组长度。

```
# 字典.3.6之前是没有的 key--->values  变量: 变量携带数据位置
# 3.7以后是有顺序的.
data = {'Name':['关羽', '刘备', '张飞', '曹操'],'Age':[28,34,29,42]}
# 通过字典创建DataFrame
df = pd.DataFrame(data)
print(df)
# 输入标签
print(df.index)
```

```
  Name  Age
0   关羽   28
1   刘备   34
2   张飞   29
3   曹操   42
RangeIndex(start=0, stop=4, step=1)
```

> 注意：这里使用了默认行标签，也就是 RangeIndex(0.1...n)。它生成了 0,1,2,3，并分别对应了列表中的每个元素值。

5. 添加自定义的行标签

```
# 字典
data = {'Name':['关羽', '刘备', '张飞', '曹操'],'Age':[28,34,29,42]}
# 定义行标签
index = ["rank1", "rank2", "rank3", "rank4"]
# 通过字典创建DataFrame
df = pd.DataFrame(data, index=index)
print(df)
# 输入行标签
print(df.index)
# 输出列表标签
print(df.columns)

```

```
      Name  Age
rank1   关羽   28
rank2   刘备   34
rank3   张飞   29
rank4   曹操   42
Index(['rank1', 'rank2', 'rank3', 'rank4'], dtype='object')
Index(['Name', 'Age'], dtype='object')
```

6. 列表嵌套字典创建DataFrame对象

列表嵌套字典可以作为输入数据传递给 DataFrame 构造函数。默认情况下，字典的键被用作列名。

```

data = [{'a': 1, 'b': 2},{'a': 5, 'b': 10, 'c': 20}]
#df = pd.DataFrame(data)
df = pd.DataFrame(data, index=['first', 'second'])

print(df)
```

```
        a   b     c
first   1   2   NaN
second  5  10  20.0
```

注意：如果其中某个元素值缺失，也就是字典的 key 无法找到对应的 value，将使用 NaN 代替。

如何使用列表嵌套字典创建一个 DataFrame 对象,可以设置结果需要那些列

```python
data = [{'a': 1, 'b': 2},{'a': 5, 'b': 10, 'c': 20}]
df1 = pd.DataFrame(data, index=['first', 'second'], columns=['a', 'b'])

# 注意：因为 b1 在字典键中不存在，所以对应值为 NaN。
df2 = pd.DataFrame(data, index=['first', 'second'], columns=['a', 'b1'])
print("===========df1============")
print(df1)
print("===========df2============")
print(df2)
```

```
===========df1============
        a   b
first   1   2
second  5  10
===========df2============
        a  b1
first   1 NaN
second  5 NaN
```

7. Series创建DataFrame对象

您也可以传递一个字典形式的 **Series**，从而创建一个 **DataFrame** 对象，其输出结果的行索引是所有 **index** 的合集

```python
d = {'one' : pd.Series([1, 2, 3], index=['a', 'b', 'c']),
   'two' : pd.Series([1, 2, 3, 4], index=['a', 'b', 'c', 'd'])}
df = pd.DataFrame(d)
print(df)
```

```
   one  two
a  1.0    1
b  2.0    2
c  3.0    3
d  NaN    4
```

```python
type(np.NaN)
```

```
float
```

注意：对于 one 列而言，此处虽然显示了行索引 'd'，但由于没有与其对应的值，所以它的值为 NaN。

```python
# 创建数据
data = {
    "Name":pd.Series(['xiaowang', 'Lily', 'Anne']),
    "Age":pd.Series([20, 30, 40],  dtype=float),
    "gender":pd.Series(["男", "男", "女"]),
    "salary":pd.Series([5000, 8000, 10000], dtype=float)
}
df = pd.DataFrame(data)
# int满足某列特征,会自动使用, 不满足,则自动识别
df
# 解决不同列 设置自定义数据类型
```

```css
.dataframe tbody tr th {
    vertical-align: top;
}

.dataframe thead th {
    text-align: right;
}
```

	Name	Age	gender	salary
0	xiaowang	20.0	男	5000.0
1	Lily	30.0	男	8000.0
2	Anne	40.0	女	10000.0

```

```

列操作DataFrame

DataFrame 可以使用列标签来完成数据的选取、添加和删除操作。下面依次对这些操作进行介绍。

1. 选取数据列

- 可以使用列索引，轻松实现数据选取

```
data = {'Name':['关羽', '刘备', '张飞', '曹操'],'Age':[28,34,29,42]}
# 定义行标签
index = ["rank1", "rank2", "rank3", "rank4"]
# 通过字典创建DataFrame
df = pd.DataFrame(data, index=index)
print(df)
print("=========df['Name']:取得Name列===============")
print(df['Name'])
print("=========df['Age']:取得Age列===============")
print(df['Age'])

```

```
      Name  Age
rank1   关羽   28
rank2   刘备   34
rank3   张飞   29
rank4   曹操   42
=========df['Name']:取得Name列===============
rank1    关羽
rank2    刘备
rank3    张飞
rank4    曹操
Name: Name, dtype: object
=========df['Age']:取得Age列===============
rank1    28
rank2    34
rank3    29
rank4    42
Name: Age, dtype: int64
```

```

print("=========df[['Name', 'Age']]:df选取多列===============")
print(df[['Name', 'Age']])
# 注意列不是能使用切片选取多列
print("=========df不能使用切片选取多列===============")
print(df['Name': 'Age'])   # 空DataFrame
```

```
=========df[['Name', 'Age']]:df选取多列==============
      Name  Age
rank1   关羽   28
rank2   刘备   34
rank3   张飞   29
rank4   曹操   42
=========df不能使用切片选取多列==============
Empty DataFrame
Columns: [Name, Age]
Index: []
```

没有办法直接通过标签位置去获取列

```
df[1]  # 会报错
```

2. 列添加

- 使用 **columns** 列索引标签可以实现添加新的数据列，示例如下

```
d = {'one' : pd.Series([1, 2, 3], index=['a', 'b', 'c']),
   'two' : pd.Series([1, 2, 3, 4], index=['a', 'b', 'c', 'd'])}
df = pd.DataFrame(d)

#使用df['列']=值，插入新的数据列
print ("====通过Series添加一个新的列====:")
df['three']=pd.Series([10,20,30],index=['a','b','c'])
print(df)

#将已经存在的数据列相加运算,从而创建一个新的列
print ("======将已经存在的数据列相加运算,从而创建一个新的列:=======")
df['four']=df['one']+df['three']
print(df)
```

```
====通过Series添加一个新的列====:
   one  two  three
a  1.0    1   10.0
b  2.0    2   20.0
c  3.0    3   30.0
d  NaN    4    NaN
======将已经存在的数据列相加运算,从而创建一个新的列:=======
   one  two  three  four
a  1.0    1   10.0  11.0
b  2.0    2   20.0  22.0
c  3.0    3   30.0  33.0
d  NaN    4    NaN   NaN
```

上述示例，我们初次使用了 DataFrame 的算术运算，这和 NumPy 非常相似。除了使用df[]=value的方式外，您还可以使用 insert() 方法插入新的列，示例如下：

```
df.insert(loc, column, value, allow_duplicates=False)
```

- loc : 整型,插入索引,必须验证0<=loc<=len（列）
- column : 插入列的标签,类型可以是(字符串/数字/散列对象)
- value : 数值,Series或者数组
- allow_duplicates : 允许重复,可以有相同的列标签数据,默认为False

```
info=[['王杰',18],['李杰',19],['刘杰',17]]
df=pd.DataFrame(info,columns=['name','age'])
print(df)
#注意是column参数
#数值1代表插入到columns列表的索引位置
df.insert(2,column='score',value=[91,90,75])
print("=====df.insert插入数据:=======")
print(df)
```

```
  name  age
0   王杰   18
1   李杰   19
2   刘杰   17
=====df.insert插入数据:=======
  name  age  score
0   王杰   18     91
1   李杰   19     90
2   刘杰   17     75
```

```
# 可以添加重复列标签数据
df.insert(1,column='score',value=[80,70,90],allow_duplicates=True)
print(df['score'])
```

```
   score  score
0     80     91
1     70     90
2     90     75
```

```
df.insert(1,column='score',value=[80,70,90]) # 错误 cannot insert
name, already exists
```

2. 删除数据列

- 通过 **del** 和 **pop()** 都能够删除 **DataFrame** 中的数据列,**pop**有返回值

示例如下：

```
import pandas as pd
d = {'one' : pd.Series([1, 2, 3], index=['a', 'b', 'c']),
     'two' : pd.Series([1, 2, 3, 4], index=['a', 'b', 'c', 'd']),
     'three' : pd.Series([10,20,30], index=['a','b','c'])}
df = pd.DataFrame(d)
print ("Our dataframe is:")
print(df)
#使用del删除
del df['one']
print("=======del df['one']=========")
print(df)
#使用pop方法删除
res_pop = df.pop('two')
print("=======df.pop('two')=========")
print(df)
print("=======res_pop = df.pop('two')=========")
print(res_pop)
```

```
Our dataframe is:
   one  two  three
a  1.0    1   10.0
b  2.0    2   20.0
c  3.0    3   30.0
d  NaN    4    NaN
=======del df['one']=========
   two  three
a    1   10.0
b    2   20.0
c    3   30.0
d    4    NaN
=======df.pop('two')=========
   three
a   10.0
b   20.0
c   30.0
d    NaN
=======res_pop = df.pop('two')=========
a    1
b    2
c    3
d    4
Name: two, dtype: int64
```

```
my_dict ={"name":"xiao网","age":20}
del my_dict["name"]
my_dict
```

```
{'age': 20}
```

行操作DataFrame

理解了上述的列索引操作后，行索引操作就变的简单

1. 标签选取

- 行操作需要借助loc属性来完成:按标签或布尔数组访问一组行和列

```
import pandas as pd
# 定义字典
d = {'one' : pd.Series([1, 2, 3], index=['a', 'b', 'c']),
     'two' : pd.Series([1, 2, 3, 4], index=['a', 'b', 'c', 'd'])}
# 创建DataFrame数据结构
df = pd.DataFrame(d)
print("===========df原始数据========")
print(df)
# 确定标签为b的数据
print("===========标签为b的数据========")
print(df.loc['b'])
```

```
===========df原始数据========
   one  two
a  1.0    1
b  2.0    2
c  3.0    3
d  NaN    4
===========标签为b的数据========
one    2.0
two    2.0
Name: b, dtype: float64
```

注意：loc 允许接受两个参数分别是行和列

```
# b行 one列交叉的数据
df.loc['b',"one"]
```

```
2.0
```

行和列还可以使用切片

```
# 标签为b的行到标签为d的行， 对应标签为one的列
df.loc['b':'d',"one"]   # 注意使用行标签切片,包含结束的行
```

```
b    2.0
c    3.0
d    NaN
Name: one, dtype: float64
```

```
# 注意这里和numpy整数数组索引区别
df.loc[['a','b'],["one","two"]]
# 这里两个参数,第一个代表行,第二个代表列
```

```
.dataframe tbody tr th {
    vertical-align: top;
}

.dataframe thead th {
    text-align: right;
}
```

	one	two
a	1.0	1
b	2.0	2

```
s = np.arange(12).reshape((3,4))
s
```

```
array([[ 0,  1,  2,  3],
       [ 4,  5,  6,  7],
       [ 8,  9, 10, 11]])
```

```
# 1行1列和3行4列分别相交的数据
s[[0,2],[0,3]]
```

```
array([ 0, 11])
```

```
s[[0,2],[0,3]]
```

```
array([ 0, 11])
```

2. 数值型索引和切片

- 使用数据型索引 需要使用iloc属性

直接使用索引,会优先查找的是列标签,如果找不到会报错.列没有位置索引

- 可以使用iloc :行基于整数位置的按位置选择索引

```
data = {'Name':['关羽', '刘备', '张飞', '曹操'],'Age':[28,34,29,42]}
# 定义行标签
index = ["rank1", "rank2", "rank3", "rank4"]
# 通过字典创建DataFrame
df = pd.DataFrame(data, index=index)
df
```

```
.dataframe tbody tr th {
    vertical-align: top;
}

.dataframe thead th {
    text-align: right;
}
```

	Name	Age
rank1	关羽	28
rank2	刘备	34
rank3	张飞	29
rank4	曹操	42

```
# 取得位置索引为2的数据
df.iloc[2]
```

```
Name    张飞
Age     29
Name: rank3, dtype: object
```

```
# 取得位置索引分别为0和2的数据
df.iloc[[0,2]]
```

```
.dataframe tbody tr th {
    vertical-align: top;
}

.dataframe thead th {
    text-align: right;
}
```

	Name	Age
rank1	关羽	28
rank3	张飞	29

```
# 表示行索引为0,列索引为1的数据
df.iloc[0,1]
```

```
28
```

注意:

- loc使用的是标签
- iloc使用的是位置索引

两者不能混用,比如在loc中使用位置索引,或者在iloc中使用标签索引

错误写法:

```
# 错误写法:
#df.loc[1,"Name"]

# 或者

#df.iloc[1,"Name"]
```

3. 切片操作多行选取

可以直接使用数值型切片操作行.和使用iloc同样的结果

```
data = {'Name':['关羽', '刘备', '张飞', '曹操'],'Age':[28,34,29,42]}
# 定义行标签
index = ["rank1", "rank2", "rank3", "rank4"]
# 通过字典创建DataFrame
df = pd.DataFrame(data, index=index)
df
```

```
.dataframe tbody tr th {
    vertical-align: top;
}

.dataframe thead th {
    text-align: right;
}
```

	Name	Age
rank1	关羽	28
rank2	刘备	34
rank3	张飞	29
rank4	曹操	42

```
# 取得位置索引1到3行,但是不包含3的数据
print("=====df.iloc[1:3]:=======")
print(df.iloc[1:3])
```

```
=====df.iloc[1:3]:=======
      Name  Age
rank2   刘备   34
rank3   张飞   29
```

```
# 使用切片可以直接提取行
print("=====df[1:3]:=======")
print(df[1:3])
```

```
=====df[1:3]:=======
      Name  Age
rank2   刘备   34
rank3   张飞   29
```

```

```

练习:

```
data = {
            'Name':['关羽', '刘备', '张飞', '曹操'],
            'Age':[28, 34, 29, 42],
            "Salary":[5000, 8000, 4500, 10000],
            "hobby":["python", "java", "go", "JavaScript"]
        }
# 定义行标签
index = ["rank1", "rank2", "rank3", "rank4"]
# 通过字典创建DataFrame
df = pd.DataFrame(data, index=index)
df
```

1. 取得第3行数据
2. 取得Age列数据
3. 取得Age和Salary列数据
4. 取得前3行数据
5. 取得前3行Name|Age|Salary数据
6. 取得行1和3,列Age和Salary数据

尽量使用多种方式

```

```

```

```

```

```

```

```

```

```

4. 添加数据行

使用 append() 函数，可以将新的数据行添加到 DataFrame 中，该函数会在行末追加数据行

```
df.append(other, ignore_index=False, verify_integrity=False, sort=False)
```

将"other"追加到调用者的末尾，返回一个新对象。"other"行中不在调用者中的列将作为新列添加。

- other : DataFrame或Series/dict类对象，或这些对象的列表

- **ignore_index : 默认为False,如果为True将不适用index 标签.**
- **verify_integrity : 默认为False如果为True，则在创建具有重复项的索引时引发ValueError.**
- **sort : 排序**

```
import pandas as pd
data = {
            'Name':['关羽', '刘备', '张飞', '曹操'],
            'Age':[28, 34, 29, 42],
            "Salary":[5000, 8000, 4500, 10000]
        }
df = pd.DataFrame(data)
df
```

1). 追加字典

```
d2 = {"Name":"诸葛亮", "Age":30}
#在行末追加新数据行
df3 = df.append(d2) # 需要添加 ignore_index=True
print(df3)
```

错误提示:

Can only append a Series if ignore_index=True or if the Series has a name

仅当ignore_index=True或序列有名称时，才能追加序列

或者

Series数据有name

```
d2 = {"Name":"诸葛亮", "Age":30}
#在行末追加新数据行
df3 = df.append(d2, ignore_index=True) # 需要添加
print(df3)
```

```
d2 = {"Name":"诸葛亮", "Age":30}

s = pd.Series(d2, name="a")
print(s)
#在行末追加新数据行
df3 = df.append(s) # 需要添加
print(df3)
```

```

```

2).追加列表

- 如果list是一维的,则以列的形式追加
- 如果list是二维的,则以行的形式追加
- 如果list是三维的,只添加一个值

注意:使用append可能会出现相同的index,想避免的话,可以使用ignore_index=True

```
data = [
            [1, 2, 3, 4],
            [5, 6, 7, 8]
       ]

df = pd.DataFrame(data)
print(df)
```

- list是一维,则以列的形式追加

```
a_l = [10,20]

df3 = df.append(a_l) # 需要添加
print(df3)
```

```
a_l = [10,20,30]
df3 = df.append(a_l,ignore_index=True) # 需要添加
print(df3)
```

- list是二维的,则以行的形式追加

```
a_l = [[10,"20",30]]
df4 = df.append(a_l) # 需要添加
print(df4)
print("==========使用:ignore_index=True===========")
df5 = df.append(a_l,ignore_index=True) # 需要添加
print(df5)
```

```
#### 5. 删除数据行

您可以使用行索引标签，从 DataFrame 中删除某一行数据。如果索引标签存在重复，那么它们将被一起删除。示例如下：
```

```
df = pd.DataFrame([[1, 2], [3, 4]], columns = ['a','b'])

df2 = pd.DataFrame([[5, 6], [7, 8]], columns = ['a','b'])

df = df.append(df2)
print("=======源数据df=======")
```

```
print(df)
#注意此处调用了drop()方法,注意drop默认不会更改源数据
df1 = df.drop(0)
print("=======修改后数据df1=======")
print(df1)

print("=======源数据df=======")
print(df)
```

```
# 两种方式解决:
# 1. 源数据=修改后的数据
df = df.drop(0)
# 2.添加inplace=True
df = df.drop(1)
```

```

```

常用属性和方法汇总

名称	属性&方法描述
T	行和列转置。
axes	返回一个仅以行轴标签和列轴标签为成员的列表。
dtypes	返回每列数据的数据类型。
empty	DataFrame中没有数据或者任意坐标轴的长度为0，则返回True
columns	返回DataFrame所有列标签
shape	返回一个元组，获取行数和列数,表示了 DataFrame 维度。
size	DataFrame中的元素数量。
values	使用 numpy 数组表示 DataFrame 中的元素值。
head()	返回前 n 行数据。
tail()	返回后 n 行数据。
rename()	rename(columns=字典) ,修改列名
info()	可以显示信息，例如行数/列数，总内存使用量，每列的数据类型以及不缺少值的元素数
sort_index()	默认根据行标签对所有行排序，或根据列标签对所有列排序，或根据指定某列或某几列对行排序。
sort_values()	既可以根据列数据，也可根据行数据排序

```
import pandas as pd
data = {
            'Name':['关羽', '刘备', '张飞', '曹操'],
            'Age':[28, 34, 29, 42],
            "Salary":[5000, 8000, 4500, 10000]
        }
df = pd.DataFrame(data)
df
```

转置

返回 **DataFrame** 的转置，也就是把行和列进行交换。

```
df.T
```

axes

返回一个行标签、列标签组成的列表。

```
df.axes
```

dtypes

返回Series,每一列的数据类型。示例如下：

```
df.dtypes
```

```

```

empty

返回一个布尔值，判断输出的数据对象是否为空，若为 True 表示对象为空。

```
df.empty  # 返回假
```

```
# 创建一个空的DataFrame
empty_df = pd.DataFrame()
empty_df.empty   # 返回真
```

columns

返回DataFrame所有列标签

```
df.columns
```

```
# 可以通过df.columns的个数获取DataFrame列个数
len(df.columns)
```

```
df.columns.size
```

shape

返回一个元组，获取行数和列数,表示了 DataFrame 维度。

```
df.shape
```

```
row_num,column_num = df.shape
print(row_num,column_num )
```

values

以 ndarray 数组的形式返回 DataFrame 中的数据

```
df.values
```

head()&tail()查看数据

```
#获取前3行数据
df.head(3)
```

```
#获取后3行数据
df.tail(3)
```

修改列名rename()

DataFrame.rename(index=None, columns=None, inplace=False)

- **index:** 修改后的行标签
- **columns:** 修改后的列标签
- **inplace:** 默认为**False**,不改变源数据,返回修改后的数据. **True**更改源数据

可以修改部分行或者列

```
df
```

```
# 修改变量df的行标签
df.rename(index={1:"row2", 2:"row3"})
```

```
# 修改变量df的列标签
df.rename(columns = {"Name":"name", "Age":"age"})
```

```
df
```

```
# 添加inplace参数,修改原数据
df.rename(index={1:"row2", 2:"row3"}, columns = {"Name":"name",
"Age":"age"}, inplace=True)
```

```
df
```

info()函数

用于打印DataFrame的简要摘要，显示有关DataFrame的信息，包括索引的数据类型dtype和列的数据类型dtype，非空值的数量和内存使用情况。

```
# 创建一组数据
data = {"name":"诸葛亮","age":30}
# 将数据追加到df数据中
df = df.append(data, ignore_index =True)
df
```

```
df.info()
```

我们来看一看都有些什么信息：

- **<class 'pandas.core.frame.DataFrame'>:** 是说数据类型为DataFrame
- **RangeIndex: 5 entries, 0 to 4:** 有5条数据（5行），索引为0-4
- **Data columns (total 3 columns):** 该数据帧有3列
- **#:** 索引号，不用太在意
- **column:** 每列数据的列名
- **Non-Null count:** 每列数据的数据个数，缺失值NaN不作计算。可以看出上面Salary列数据有缺失值。
- **Dtype:** 数据的类型。
- **dtypes: float64(1), int64(1), object(1):** 数据类型的统计
- **memory usage: 248.0+ bytes:** 该数据帧占用的运行内存（RAM）

df. sort_index()

`sort_index(axis=0, ascending=True, inplace=False)`

作用：默认根据行标签对所有行排序，或根据列标签对所有列排序，或根据指定某列或某几列对行排序。

注意：df.sort_index()可以完成和df.sort_values()完全相同的功能，但python更推荐用只用df.sort_index()对“根据行标签”和“根据列标签”排序，其他排序方式用df.sort_values()。

- **axis：** 0按照行名排序；1按照列名排序
- **ascending：** 默认True升序排列；False降序排列
- **inplace：** 默认False，否则排序之后的数据直接替换原来的数据

```
df = pd.DataFrame({'b':[1,2,2,3],'a':[4,3,2,1],'c':[1,3,8,2]},index=[2,0,1,3])
df
```

```
#默认按“行标签”升序排序，或df.sort_index(axis=0, ascending=True)
df.sort_index()
```

```
#按“列标签”升序排序
df.sort_index(axis=1)
```

```
#按“列标签”升序排序
df.sort_index(axis=1, inplace=True)
df
```

```
## df.sort_values()
`DataFrame.sort_values(by, axis=0, ascending=True, inplace=False, kind='quicksort', na_position='last')`

作用：既可以根据列数据，也可根据行数据排序。

注意：必须指定by参数，即必须指定哪几行或哪几列；无法根据index名和columns名排序（由.sort_index()执行）

- by：str or list of str；如果axis=0，那么by="列名"；如果axis=1，那么by="行名"。
- axis：{0 or ‘index’, 1 or ‘columns’}, default 0，默认按照列排序，即纵向排序；如果为1，则是横向排序。
- ascending：布尔型，True则升序，如果by=['列名1','列名2']，则该参数可以是[True, False]，即第一字段升序，第二个降序。
- inplace：布尔型，是否用排序后的数据框替换现有的数据框。
- na_position：{‘first’, ‘last’}, default ‘last’，默认缺失值排在最后面。
```

```
# 源数据
df = pd.DataFrame({'b':[1,2,3,2],'a':[4,3,2,1],'c':[1,3,8,2]},index=[2,0,1,3])
df
```

1. 按b列升序排序

```
print(df)
#等同于df.sort_values(by='b',axis=0)
df.sort_values(by='b')
```

2. 先按b列降序，再按a列升序排序

```
print(df)
df.sort_values(by=['b','a'],ascending=[False,True])
#等同于df.sort_values(by=['b','a'],axis=0,ascending=[False,True])
```

3. 按行**3**升序排列

```
print(df)
df.sort_values(by=3,axis=1) #必须指定axis=1
```

4. 按行**3**升序，行**0**降排列

```
print(df)
df.sort_values(by=[3,0],axis=1,ascending=[True,False])
```

注意: 指定多列（多行）排序时，先按排在前面的列（行）排序，如果内部有相同数据，再对相同数据内部用下一个列（行）排序，

以此类推。如何内部无重复数据，则后续排列不执行。即首先满足排在前面的参数的排序，再排后面参数

```

```

```

```

补充: 错误提示

错误提示:

- **If using all scalar values, you must pass an index:** (直接传入一组标量,必须通过index写入)

```
# 一组数据,字典的value只有一个值
dict_1 = {"Name":"诸葛亮", "Age":30}
df = pd.DataFrame(dict_1) # 提示:If using all scalar values, you must pass an index
df
```

```
# 方案1:将字典的value修改为列表
dict_1 = {"Name":["诸葛亮"], "Age":[30]}
df = pd.DataFrame(dict_1)
df
```

```python
# 方案2:创建DF是添加一个index参数为[0]
dict_1 = {"Name":["诸葛亮"], "Age":[30]}
df = pd.DataFrame(dict_1,index =[0])
df
```

错误提示:

- **The truth value of a DataFrame is ambiguous. Use a.empty, a.bool(), a.item(), a.any() or a.all().(数据为真是模糊的)**

直接对DataFrame为空进行判断,出错

```python
df = pd.DataFrame()
if df:
    print("df中存在数据")
else:
    print("df中不存在数据")
```

```python
df = pd.DataFrame()
if df.bool:
    print("df中存在数据")
else:
    print("df中不存在数据")
```

作业

1. 用三种不同的方法，创建以下Dataframe（保证columns和index一致，值不做要求）

结果Dataframe为：

	four	one	three	two
a	4	1	3	2
b	5	2	4	3
c	6	3	5	4
d	7	4	6	5
e	8	5	7	6

2. 如图创建Dataframe(4*4，值为0-100的随机数)，通过索引得到以下值
    ① 索引得到b，c列的所有值
    ② 索引得到第三第四行的数据
    ③ 按顺序索引得到two，one行的值

```
    ④ 索引得到大于50的值
           a          b          c          d
one    60.936882  34.198569  86.933961  63.217850
two    93.910622   8.843498  12.482240  35.940462
three  11.350391  40.704308  50.524502   5.215897
four    5.777448  75.515444  96.847913  57.683561


3 .创建一个3*3，值在0-100区间随机值的Dataframe（如图），分别按照index和第二列值大小，降序排序

创建Dataframe为：
      v1         v2         v3
a   6.477556   9.470260  99.929419
b  47.411645  50.873012  33.376488
c  65.374675  23.431663  43.404255
-------
按照index降序：
      v1         v2         v3
c  65.374675  23.431663  43.404255
b  47.411645  50.873012  33.376488
a   6.477556   9.470260  99.929419
-------
按照第二列值大小降序：
     v1         v2         v3
b  47.411645  50.873012  33.376488
c  65.374675  23.431663  43.404255
a   6.477556   9.470260  99.929419
```